

Adaboost

2. 前向分步算法

2.1 前向分步算法的过程

对于一个加法模型 $f(\mathbf{x}) = \sum_{m=1}^M \beta_m b(\mathbf{x}; \gamma_m)$ ，由 M 个基函数 b ，通过系数 β 线性相加而成，基函数 b 输入 \mathbf{x} ，参数是 γ_m 。

对于加法模型 $f(\mathbf{x})$ 而言，可以学习的参数有 β_m 和 γ_m （这两个参数其实是外层和内层的关系）。定义 $f(\mathbf{x})$ 的损失函数为 $L(y, f(\mathbf{x}))$ ，那么学习 $f(\mathbf{x})$ 的参数过程其实是最小化损失函数

$$\min_{\beta_m, \gamma_m} \sum_{i=1}^N L(y^{(i)}, f(\mathbf{x})) = \min_{\beta_m, \gamma_m} \sum_{i=1}^N L\left(y^{(i)}, \sum_{m=1}^M \beta_m b(x^{(i)}; \gamma_m)\right)$$

要直接优化这个问题比较复杂。相对的，前向分步算法，通过从前向后，每一步只学习一个基函数及其系数，逐步逼近优化目标函数，从而简化求解复杂度。这样就把内层的 $\sum_{m=1}^M$ 去掉，从而变成

$$\min_{\beta, \gamma} \sum_{i=1}^N L(y^{(i)}, \beta b(x^{(i)}; \gamma))$$

通过调整每步的 β 和 γ 从而最小化当前步骤的损失函数。这样，前向分步算法将同时求解从 $m = 1$ 到 M 所有的参数 β 和 γ_m 的优化问题，变成了逐层求解 β 和 γ 的优化问题。

具体来看，第 m 层的优化问题为

$$\arg \min_{\beta, \gamma} \sum_{i=1}^N L(y^{(i)}, f_{m-1}(\mathbf{x}^{(i)}) + \beta b(\mathbf{x}^{(i)}; \gamma))$$

注意到，第 m 层计算数据点类别的函数，除了包含第 m 层的基函数以外，还要包括前 $m - 1$ 层训练好的加法模型 $f_{m-1}(\mathbf{x}^{(i)})$ 。求解这个 \min 方法得到第 m 层的 (β_m^*, γ_m^*) ，并且更新加法模型

$$f_m(\mathbf{x}^{(i)}) = f_{m-1}(\mathbf{x}^{(i)}) + \beta_m^* b(\mathbf{x}^{(i)}; \gamma_m^*)$$

求解 $1 \cdots M$ 层的最优参数，然后线性相加，得到最后的最优加法模型 $f(\mathbf{x}) = f_M(\mathbf{x}) = \sum_{m=1}^M \beta_m^* b(\mathbf{x}; \gamma_m^*)$

2.2 前向分步算法与Adaboost算法的关系

当前向分步算法的损失函数是指数函数时，学习的过程等价于Adaboost算法。假设前向分步算法的基函数用 $G(\mathbf{x})$ 表示，系数用 α_m 表示。则加法模型可以表示成下面的式子。

$$f(\mathbf{x}) = \sum_{m=1}^M \alpha_m G_m(\mathbf{x})$$

假设经过 $m - 1$ 轮迭代得到了 $f_{m-1}(\mathbf{x})$ ，

$$\begin{aligned} f_{m-1}(\mathbf{x}) &= f_{m-2}(\mathbf{x}) + \alpha_{m-1}^* G_{m-1}(\mathbf{x}) \\ &= \alpha_1^* G_1(\mathbf{x}) + \alpha_2^* G_2(\mathbf{x}) + \cdots + \alpha_{m-1}^* G_{m-1}(\mathbf{x}) \end{aligned}$$

假设在第 M 轮迭代中，得到了最优的参数 α_M^* 和分类器 $G_m(\mathbf{x})$ ，同时 $f_m(\mathbf{x}) = f_{m-1}(\mathbf{x}) + \alpha_m^* G_m(\mathbf{x})$

为了得到 α_M^* 和分类器 $G_m(\mathbf{x})$ ，必须求解以下目标函数

$$\begin{aligned} &\arg \min_{\alpha, G} \sum_{i=1}^N \exp[-y^{(i)}(f_{m-1}(\mathbf{x}^{(i)}) + \alpha G(\mathbf{x}^{(i)}))] \\ &= \sum_{i=1}^N \exp[-y^{(i)} f_{m-1}(\mathbf{x}^{(i)}) - y^{(i)} \alpha G(\mathbf{x}^{(i)})] \\ &= \sum_{i=1}^N \exp(-y^{(i)} f_{m-1}(\mathbf{x}^{(i)})) \exp(-y^{(i)} \alpha G(\mathbf{x}^{(i)})) \\ &= \sum_{i=1}^N \bar{w}_m^{(i)} \exp[-y^{(i)} \alpha G(\mathbf{x}^{(i)})] \quad \text{定义 } \bar{w}_m^{(i)} = \exp(-y^{(i)} f_{m-1}(\mathbf{x}^{(i)})) \end{aligned}$$

求解这个关于 α 和 $G_m(\mathbf{x})$ 的最小化问题，可以分两步走，先对 $G_m(\mathbf{x})$ 求最小化，再对 α 求最小化。

在第一步对 $G_m(\mathbf{x})$ 求最小化， α 可以是任意值，但是因为 α 在 $\exp[-y^{(i)} \alpha G(\mathbf{x}^{(i)})]$ 中，为了不影响幂的符号，这里定义 $\alpha > 0$

把所有可以不考虑的项去掉后，目标函数变成

$$\arg \min_G \sum_{i=1}^N \bar{w}_m^{(i)} \exp(-y^{(i)} G(\mathbf{x}^{(i)}))$$

注意到基本分类器 $G_m(\mathbf{x}) : \mathcal{X} \rightarrow \{-1, +1\}$ ，所以当 $y^{(i)} = G(\mathbf{x}^{(i)})$ 时， $-y^{(i)} G(\mathbf{x}^{(i)}) = -1$ ；当 $y^{(i)} \neq G(\mathbf{x}^{(i)})$ 时， $-y^{(i)} G(\mathbf{x}^{(i)}) = 1$ 。为了使得这个求和公式得到的结果最小，因为 \exp 是一个单调增函数，所以要尽量使得 $y^{(i)} \neq G(\mathbf{x}^{(i)})$ 的情况越少越好。这也很直观，其实就是要使得基本分类器 $G(\mathbf{x})$ 要尽可能不分错。

所以优化以下式子等价于对 $G_m(\mathbf{x})$ 求最小化，从而得到 $G_m^*(\mathbf{x})$ 。

$$G_m^*(\mathbf{x}) = \arg \min_G \sum_{i=1}^N \bar{w}_m^{(i)} I(y^{(i)} \neq G(\mathbf{x}^{(i)}))$$

第二步针对 α 进行最小化。

$$\begin{aligned} &\sum_{i=1}^N \bar{w}_m^{(i)} \exp[-y^{(i)} \alpha G(\mathbf{x}^{(i)})] \\ &= \sum_{i: y^{(i)} = G(\mathbf{x}^{(i)})} \bar{w}_m^{(i)} \exp(-\alpha) + \sum_{i: y^{(i)} \neq G(\mathbf{x}^{(i)})} \bar{w}_m^{(i)} \exp(\alpha) \\ &= \exp(-\alpha) \left(\sum_{i=1}^N \bar{w}_m^{(i)} - \sum_{i: y^{(i)} \neq G(\mathbf{x}^{(i)})} \bar{w}_m^{(i)} \right) + \exp(\alpha) \sum_{i: y^{(i)} \neq G(\mathbf{x}^{(i)})} \bar{w}_m^{(i)} \\ &= (\exp(\alpha) - \exp(-\alpha)) \sum_{i: y^{(i)} \neq G(\mathbf{x}^{(i)})} \bar{w}_m^{(i)} + \exp(-\alpha) \sum_{i=1}^N \bar{w}_m^{(i)} \end{aligned}$$

用 $G_m^*(\mathbf{x})$ 代入，对 α 求偏导数，得到

$$(e^{\alpha} + e^{-\alpha}) \sum_{i; y^{(i)} \neq G(\mathbf{x}^{(i)})} \bar{w}_m^{(i)} - e^{-\alpha} \sum_{i=1}^N \bar{w}_m^{(i)}$$

令偏导数等于0，整理后得到

$$e^{\alpha} \sum_{i; y^{(i)} \neq G(\mathbf{x}^{(i)})} \bar{w}_m^{(i)} = e^{-\alpha} \left(\sum_{i=1}^N \bar{w}_m^{(i)} - \sum_{i; y^{(i)} \neq G(\mathbf{x}^{(i)})} \bar{w}_m^{(i)} \right) = e^{-\alpha} \sum_{i; y^{(i)} = G(\mathbf{x}^{(i)})} \bar{w}_m^{(i)}$$

把 α 整理到一边可得

$$e^{2\alpha} = \frac{\sum_{i; y^{(i)} = G(\mathbf{x}^{(i)})} \bar{w}_m^{(i)}}{\sum_{i; y^{(i)} \neq G(\mathbf{x}^{(i)})} \bar{w}_m^{(i)}}$$

得到

$$\alpha = \frac{1}{2} \log \frac{\sum_{i; y^{(i)} = G(\mathbf{x}^{(i)})} \bar{w}_m^{(i)}}{\sum_{i; y^{(i)} \neq G(\mathbf{x}^{(i)})} \bar{w}_m^{(i)}}$$

定义误差率

$$e_m = \frac{\sum_{i; y^{(i)} \neq G(\mathbf{x}^{(i)})} \bar{w}_m^{(i)}}{\sum_{i=1}^N \bar{w}_m^{(i)}}$$

代入 α 中可得

$$\alpha = \frac{1}{2} \log \frac{1 - e_m}{e_m}$$

这里的 α 就是求得的最优 α_m^*

根据加法模型的定义， $f_m(\mathbf{x}) = f_{m-1}(\mathbf{x}) + \alpha_m G_m(\mathbf{x})$ ，所以 $f_{m-1}(\mathbf{x}) = f_m(\mathbf{x}) - \alpha_m G_m(\mathbf{x})$ ，将其带入 \bar{w}_m 的表达式有

$$\begin{aligned} \bar{w}_m &= \exp(-y f_{m-1}(\mathbf{x})) \\ &= e^{-y(f_m(\mathbf{x}) - \alpha_m G_m(\mathbf{x}))} \\ &= e^{-y f_m(\mathbf{x}) + y \alpha_m G_m(\mathbf{x})} \\ &= \bar{w}_{m+1} e^{y \alpha_m G_m(\mathbf{x})} \end{aligned}$$

整理得到

$$\bar{w}_{m+1} = \bar{w}_m e^{-y \alpha_m G_m(\mathbf{x})}$$

可以看到，误差率 e_m ，基函数 $G_m \mathbf{x}$ 的系数 α_m ，还有权值更新过程 \bar{w}_{m+1} 都和1.1节中Adaboost算法介绍的一致，因此对于前向分步算法而言，当损失函数为指数函数时，等价于Adaboost算法。