

HMM模型--参数学习

在上一个文档中，对HMM模型应用的三种问题，分为概率计算、参数学习、预测。在本文中对参数学习问题进行介绍。

3. 参数学习

HMM的参数是 $\lambda = (A, B, \pi)$ ，分别表示状态转移概率，观测概率，以及初始的状态概率。根据拿到的数据是有观测和状态序列，还是仅有观测数据，分为有监督学习和无监督学习了。

3.1 有监督学习

利用有监督学习去估计HMM的参数非常简单，利用Bernoulli大数定理的结论：频率的极限就是概率，进行HMM参数估计。

假设给定数据集 D ，包含有 S 个样本，每个样本为长度相等的状态序列 I 和观测序列 O 。

$$D = \{(O_1, I_1), (O_2, I_2), \dots, (O_S, I_S)\}$$

1. 估计转移概率 a_{ij} ：状态从 t 时刻的 i 转移到 $t + 1$ 时刻的 j

统计样本集里，前一时刻位于状态 i ，后一时刻位于状态 j 的频数，记作 A_{ij} 。则

$$\hat{a}_{ij} = \frac{A_{ij}}{\sum_{j=1}^N A_{ij}}, \quad i = 1, 2, \dots, N; j = 1, 2, \dots, N$$

2. 观测概率 $b_j(k)$ ：在状态 j 的情况下得到了观测 k

统计样本集里，状态为 j ，并且观测为 k 的频数，记作 B_{jk} ，则

$$\hat{b}_j(k) = \frac{B_{jk}}{\sum_{k=1}^M B_{jk}}, \quad j = 1, 2, \dots, N; k = 1, 2, \dots, M$$

3. 初始状态 π_i

统计样本集里，初始状态为 i 的样本个数，记作 S_i

$$\hat{\pi}_i = \frac{S_i}{S}$$

3.2 Baum-Welch算法

如果没有标注数据，则为非监督学习，采用BW算法。假设给定训练数据集 D ，包含有 S 个样本

$$D = \{O_1, O_2, \dots, O_S\}$$

每个样本为长度为 T 的观测序列，没有状态序列。将观测序列数据看成观测数据 O ，状态序列数据看成隐数据 I ，则观测数据 O 的似然，可以表示成

$$P(O|\lambda) = \sum_I P(O|I, \lambda) P(I|\lambda) = \sum_I P(O, I|\lambda)$$

对含有隐状态的极大似然估计问题，采用EM算法求解。

在EM算法的E步，定义Q函数。假设当前的模型估计的参数为 $\bar{\lambda}$ ，在Q函数中的变量是 λ 。因此Q函数可以表示为

$$\begin{aligned} Q(\lambda, \bar{\lambda}) &= \sum_I (\log P(O, I|\lambda)) P(I|O, \bar{\lambda}) \\ &= \sum_I (\log P(O, I|\lambda)) \frac{P(I, O|\bar{\lambda})}{P(O|\bar{\lambda})} \\ &\propto \sum_I (\log P(O, I|\lambda)) P(I, O|\bar{\lambda}) \end{aligned}$$

这是根据EM算法推导出的Q函数。但是在BW算法中，直接将Q函数定义成

$$Q(\lambda, \bar{\lambda}) = \sum_I (\log P(O, I|\lambda)) P(I, O|\bar{\lambda})$$

其中的 $P(O, I|\lambda)$ 把参数代入，展开可表达为

$$P(O, I|\lambda) = \pi_{i_1} b_{i_1}(o_1) a_{i_1 i_2} b_{i_2}(o_2) \dots a_{i_{T-1} i_T} b_{i_T}(o_T)$$

代入Q函数中，可得

$$Q(\lambda, \bar{\lambda}) = \sum_I (\log \pi_{i_1}) P(I, O|\bar{\lambda}) + \sum_I \left(\sum_{t=1}^{T-1} \log a_{i_t i_{t+1}} \right) P(I, O|\bar{\lambda}) + \sum_I \left(\sum_{t=1}^T \log b_{i_t}(o_t) \right) P(I, O|\bar{\lambda})$$

接下来为EM算法的M步，对Q函数进行极大似然估计。把Q函数对模型参数 A, B, π 求偏导数。

观察Q函数，为三项相加的形式。之所以整理成上面的样子，是因为每一项都只和一个参数有关，因此求导过程只需要考虑其中的一项即可。

首先是 π ，Q函数的第一项，可以写成

$$\sum_I (\log \pi_{i_1}) P(I, O|\bar{\lambda}) = \sum_{i=1}^N \log \pi_i P(O, i_1 = i|\bar{\lambda})$$

由于 π 是概率，因此满足 $\sum_{i=1}^N \pi_i = 1$ 。因此要把约束，利用拉格朗日乘子法，放进目标函数中。因此拉格朗日函数为

$$\sum_{i=1}^N \log \pi_i P(O, i_1 = i|\bar{\lambda}) + \gamma \left(\sum_{i=1}^N \pi_i - 1 \right)$$

求对 π_i 的偏导数，令其等于0。

$$\frac{\partial}{\partial \pi_i} \left[\sum_{i=1}^N \log \pi_i P(O, i_1 = i|\bar{\lambda}) + \gamma \left(\sum_{i=1}^N \pi_i - 1 \right) \right] = 0$$

因为对第 i 个 π 求导数，因此只需考虑 \sum 中的第 i 项，得到

$$\frac{P(O, i_1 = i | \bar{\lambda})}{\pi_i} + \gamma = 0$$

整理得到

$$\pi_i \gamma = -P(O, i_1 = i | \bar{\lambda})$$

两边对 i 求和，即

$$\begin{aligned} \sum_{i=1}^N \pi_i \gamma &= \sum_{i=1}^N -P(O, i_1 = i | \bar{\lambda}) \\ &= \gamma \sum_{i=1}^N \pi_i = -P(O | \bar{\lambda}) = \gamma \end{aligned}$$

将 γ 带回 $\pi_i \gamma = -P(O, i_1 = i | \bar{\lambda})$ 得到

$$\pi_i = \frac{P(O, i_1 = i | \bar{\lambda})}{P(O | \bar{\lambda})}$$

从而可以得到 π_i 的更新值的计算公式。

接着是第二项 $a_{i_t i_{t+1}}$ 。Q函数的第二项可以写成

$$\sum_I \left(\sum_{t=1}^{T-1} \log a_{i_t i_{t+1}} \right) P(I, O | \bar{\lambda}) = \sum_{i=1}^N \sum_{j=1}^N \sum_{t=1}^{T-1} \log a_{ij} P(O, i_t = i, i_{t+1} = j | \bar{\lambda})$$

注意到转移概率 a_{ij} 具有约束条件 $\sum_{j=1}^N a_{ij} = 1$ ，因此同样利用拉格朗日乘子法，写出拉格朗日函数

$$\sum_{i=1}^N \sum_{j=1}^N \sum_{t=1}^{T-1} \log a_{ij} P(O, i_t = i, i_{t+1} = j | \bar{\lambda}) + \zeta \left(\sum_{j=1}^N a_{ij} - 1 \right)$$

对 a_{ij} 求偏导，令其等于0

$$\frac{\partial}{\partial a_{ij}} \left[\sum_{i=1}^N \sum_{j=1}^N \sum_{t=1}^{T-1} \log a_{ij} P(O, i_t = i, i_{t+1} = j | \bar{\lambda}) + \zeta \left(\sum_{j=1}^N a_{ij} - 1 \right) \right] = 0$$

只需考虑 t 时刻等于 i ， $t+1$ 时刻等于 j 的情况，因此得到

$$\frac{\sum_{t=1}^{T-1} P(O, i_t = i, i_{t+1} = j | \bar{\lambda})}{a_{ij}} + \zeta = 0$$

得到

$$a_{ij} \zeta = - \sum_{t=1}^{T-1} P(O, i_t = i, i_{t+1} = j | \bar{\lambda})$$

两边对 j 求和，得到

$$\begin{aligned}
\sum_{j=1}^N a_{ij} \zeta &= - \sum_{t=1}^{T-1} \sum_{j=1}^N P(O, i_t = i, i_{t+1} = j | \bar{\lambda}) \\
&= \zeta = - \sum_{t=1}^{T-1} P(O, i_t = i | \bar{\lambda})
\end{aligned}$$

将 ζ 带回 $a_{ij} \zeta = - \sum_{t=1}^{T-1} P(O, i_t = i, i_{t+1} = j | \bar{\lambda})$ ，整理得到

$$a_{ij} = \frac{\sum_{t=1}^{T-1} P(O, i_t = i, i_{t+1} = j | \bar{\lambda})}{\sum_{t=1}^{T-1} P(O, i_t = i | \bar{\lambda})}$$

最后对 $b_j(k)$ 求偏导，构造拉格朗日函数，整理得到

$$b_j(k) = \frac{\sum_{t=1}^T P(O, i_t = j | \bar{\lambda}) I(o_t = v_k)}{\sum_{t=1}^T P(O, i_t = j | \bar{\lambda})}$$

注意，只有在 $o_t = v_k$ 的时候， $b_j(o_t)$ 对 $b_j(k)$ 的偏导数才不为零， $I(o_t = v_k)$ 表示如果括号里面的条件不满足，则该函数为0。

在第二节的结尾，我们定义了 $\xi_t(i, j) = P(i_t = i, i_{t+1} = j | O, \lambda)$ 以及 $\gamma_t(i) = \frac{P(i_t=i, O|\lambda)}{\sum_{i=1}^N P(i_t=i, O|\lambda)}$ ，代入 $a_{ij}, b_j(k), \pi_i$ ，整理得到

$$\begin{aligned}
a_{ij} &= \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)} \\
b_j(k) &= \frac{\sum_{t=1, o_t=v_k}^T \gamma_t(j)}{\sum_{t=1}^T \gamma_t(j)} \\
\pi_i &= \gamma_1(i)
\end{aligned}$$

因此，整体的BW算法，为

1. 先初始化 $p_i^{(0)}, A^{(0)}, B^{(0)}$ ，作为HMM模型初始化的参数。
2. 利用上面介绍的方法，反复交替计算 $a_{ij}, b_j(k), \pi_i$ 和计算 γ 和 ξ 。
3. 得到最终参数 $\lambda^{(n+1)} = (A^{(n+1)}, B^{(n+1)}, \pi^{(n+1)})$ 。